
DataCo SMART SUPPLY CHAIN FOR BIG DATA ANALYSIS

Data Source
DataCo Global Company



Data Analysis Team


- Eslam Mohamed
- Ebrahim Elnaqer
- Mahmoud Elafandy
- Abdullah Elbelawy
- Radwan Mohamed

- One of the most in-demand fields
- Big Data (180519 Raw, 53 Columns)
- A lot of challenges



**Why
This
Project?**

WHAT IS THIS DATA ABOUT?



01

DATA CLEANING

Tools used
Python & Excel

Type	Days for shipping (real)	Days for shipment (scheduled)	Benefit per order	Sales per customer	Delivery Status
------	--------------------------	-------------------------------	-------------------	--------------------	-----------------

type	shipping_days_actual	shipping_days_scheduled	profit_per_order	delivery_status
------	----------------------	-------------------------	------------------	-----------------

```

df[['product_status', 'product_image', 'customer_password', 'customer_email']].head(5)
[56] ✓ 0.0s
...

```

	product_status	product_image	customer_password	customer_email
0	0	http://images.acmesports.sports/Smart+watch	XXXXXXXXXX	XXXXXXXXXX
1	0	http://images.acmesports.sports/Smart+watch	XXXXXXXXXX	XXXXXXXXXX
2	0	http://images.acmesports.sports/Smart+watch	XXXXXXXXXX	XXXXXXXXXX
3	0	http://images.acmesports.sports/Smart+watch	XXXXXXXXXX	XXXXXXXXXX
4	0	http://images.acmesports.sports/Smart+watch	XXXXXXXXXX	XXXXXXXXXX

```

# Redundancy and useless columns cleaning
df.drop(columns=['product_status', 'product_image', 'customer_password', 'customer_email',
                 'order_customer_id', 'order_item_product_price', 'order_profit_per_order',
                 'sales_per_customer', 'product_category_id', 'order_product_id'], inplace=True)
[57] ✓ 0.0s

```

```

df.shape
[58] ✓ 0.0s
...
(180519, 43)

```

BEFORE

```
df.dtypes[df.dtypes == 'object']
# to date 'order_date', 'shipping_date'
```

[97] ✓ 0.0s

...	type	object
	delivery_status	object
	category_name	object
	customer_city	object
	customer_country	object
	customer_fname	object
	customer_lname	object
	customer_segment	object
	customer_state	object
	customer_street	object
	department_name	object
	market	object
	order_city	object
	order_country	object
	order_date	object
	order_region	object
	order_state	object
	order_status	object
	product name	object
	shipping_date	object
	shipping_mode	object
	dtype:	object

```
df.dtypes[df.dtypes == 'int64']
```

[96] ✓ 0.0s

...	shipping_days_actual	int64
	shipping_days_scheduled	int64
	late_delivery_risk	int64
	category_id	int64
	customer_id	int64
	department_id	int64
	order_id	int64
	order item id	int64
	order item quantity	int64
	product id	int64
	dtype:	object

```
df.dtypes[df.dtypes == 'float64']
```

[95] ✓ 0.0s

...	profit per order	float64
	customer zipcode	float64
	latitude	float64
	longitude	float64
	order item discount	float64
	order item discount rate	float64
	order item profit ratio	float64
	sales	float64
	order item total	float64
	order zipcode	float64
	product description	float64
	product price	float64
	dtype:	object

AFTER

```
df.dtypes[df.dtypes == 'int64']
```

[191] ✓ 0.0s

...	shipping_days_actual	int64
	shipping_days_scheduled	int64
	late_delivery_risk	int64
	order item quantity	int64
	dtype:	object

```
df.dtypes[df.dtypes == 'datetime64[ns]']
```

[168] ✓ 0.0s

...	order_date	datetime64[ns]
	shipping_date	datetime64[ns]
	dtype:	object

```
df.dtypes[df.dtypes == 'float64']
```

[165] ✓ 0.0s

...	profit per order	float64
	latitude	float64
	longitude	float64
	order item discount	float64
	order item discount rate	float64
	order item profit ratio	float64
	sales	float64
	order item total	float64
	product description	float64
	product price	float64
	dtype:	object

```
df.dtypes[df.dtypes == 'object']
# to date 'order_date', 'shipping_date'
```

[167] ✓ 0.0s

...	type	object
	delivery_status	object
	category_id	object
	category_name	object
	customer_city	object
	customer_country	object
	customer_fname	object
	customer_id	object
	customer_lname	object
	customer_segment	object
	customer_state	object
	customer_street	object
	customer_zipcode	object
	department_id	object
	department_name	object
	market	object
	order_city	object
	order_country	object
	order_id	object
	order item id	object
	order_region	object
	order_state	object
	order_status	object
	order_zipcode	object
	product_id	object
	product_name	object
	shipping_mode	object
	dtype:	object

NAN HANDLING

```
df.isnull().sum().sort_values(ascending=False).head()
[242] ✓ 0.2s
```

product_description	180519
order_zipcode	155679
customer_lname	8
customer_zipcode	3
delivery_status	0

dtype: int64

```
# product_description, order_zipcode
df.drop(columns=['product_description', 'order_zipcode'], inplace=True)
[243] ✓ 0.0s
```

Customer_lname column

```
# customer_lname
mask = df['customer_lname'].isna()
lname_most = df.groupby('customer_city')['customer_lname'].transform(lambda x: x.mode()[0] if not x.mode().empty else np.nan)
df['customer_lname'] = df['customer_lname'].fillna(lname_most)
df.loc[mask, 'customer_lname']
[244] ✓ 0.3s
```

41422	Smith
50447	Smith
86260	Smith
92621	Smith
97530	Smith
120404	Smith
166129	Smith
167119	Brooks

Name: customer_lname, dtype: object

Customer_zipcode column

```
# customer_zipcode
df['customer_zipcode'] = df['customer_zipcode'].replace('nan', np.nan)
mask = df['customer_zipcode'].isna()
cols_target = ['customer_zipcode', 'customer_state', 'customer_city', 'customer_street']
cols_source = ['customer_state', 'customer_city', 'customer_street']
zip_nan = df.loc[mask]
zip_nan[cols_target]
[280] ✓ 0.0s
```

customer_zipcode	customer_state	customer_city	customer_street	
35704	NaN	95758	CA	Elk Grove
46440	NaN	95758	CA	Elk Grove
82511	NaN	91732	CA	El Monte

```
df.loc[mask, cols_target] = df.loc[mask, cols_source].assign(street_nan=np.nan).values
df.loc[mask, cols_target]
[281] ✓ 0.0s
```

customer_zipcode	customer_state	customer_city	customer_street	
35704	95758	CA	Elk Grove	NaN
46440	95758	CA	Elk Grove	NaN
82511	91732	CA	El Monte	NaN

```
street_most = df.groupby('customer_city')['customer_street'].transform(
    lambda x: x.mode()[0] if not x.mode().empty else np.nan)
df['customer_street'] = df['customer_street'].fillna(street_most)
df.loc[mask, cols_target]
[77] ✓ 0.3s
```

customer_zipcode	customer_state	customer_city	customer_street	
35704	95758	CA	Elk Grove	4096 Amber Bend
46440	95758	CA	Elk Grove	4096 Amber Bend
82511	91732	CA	El Monte	2845 Jagged Oak Vale

RECATEGORYIZATION

```
df.select_dtypes(include='object').nunique().sort_values()
[283] ✓ 0.5s
```

customer_country	2
customer_segment	3
delivery_status	4
type	4
shipping_mode	4
market	5
order_status	9
department_id	11
department_name	11
order_region	23
customer_state	44
category_name	50
category_id	51
product_id	118
product_name	118
order_country	164
customer_city	562
customer_fname	782
customer_zipcode	997
order_state	1089
customer_lname	1109
order_city	3597
customer_street	6951
customer_id	20652
order_id	65752
order_item_id	180519

dtype: int64

```
df[df['category_name'] == 'Electronics']['product_name'].unique()
✓ 0.0s
```

```
array(['Under Armour Men's Compression EV SL Slide',  
      'Bridgestone e6 Straight Distance NFL San Dieg',  
      'Titleist Pro V1x Golf Balls',  
      'Bridgestone e6 Straight Distance NFL Tennessee',  
      'Under Armour Kids' Mercenary Slide',  
      'Under Armour Women's Ignite PIP VI Slide',  
      'Titleist Pro V1x High Numbers Golf Balls',  
      'Bridgestone e6 Straight Distance NFL Carolina',  
      'Under Armour Women's Ignite Slide',  
      'Titleist Pro V1x High Numbers Personalized Go',  
      'Titleist Pro V1 High Numbers Personalized Gol'], dtype=object)
```



1	category	product_name
2	Baby	Baby sweater
3	Basketball	Nike Kids' Grade School KD VI Basketball Shoe
4	Basketball	Nike Men's Kobe IX Elite Low Basketball Shoe
5	Books	Sports Books
6	Cameras	Web Camera
7	Cameras	GoPro HERO3+ Black Edition Camera
8	Camping & Hiking	ENO Atlas Hammock Straps
9	Camping & Hiking	Diamondback Women's Serene Classic Comfort Bi
10	Camping & Hiking	Diamondback Boys' Insight 24 Performance Hybr
11	Camping & Hiking	The North Face Women's Recon Backpack
12	Camping & Hiking	insta-bed Neverflat Air Mattress
13	Camping & Hiking	Diamondback Girls' Clarity 24 Hybrid Bike 201
14	Camping & Hiking	Yakima DoubleDown Ace Hitch Mount 4-Bike Rack
15	Camping & Hiking	Merrell Men's All Out Flash Trail Running Sho
16	Camping & Hiking	Merrell Women's Grassbow Sport Waterproof Hik
17	Camping & Hiking	Merrell Women's Siren Mid Waterproof Hiking B
18	Camping & Hiking	Merrell Women's Grassbow Sport Hiking Shoe
19	Cardio Equipment	Smart watch
20	Cardio Equipment	Polar FT4 Heart Rate Monitor
21	Cardio Equipment	SOLE E25 Elliptical
22	Cardio Equipment	Mio ALPHA Heart Rate Monitor/Sport Watch
23	Cardio Equipment	Polar Loop Activity Tracker
24	Cardio Equipment	Garmin Forerunner 910XT GPS Watch
25	Cardio Equipment	Fitbit The One Wireless Activity & Sleep Trac
26	Cardio Equipment	GolfBuddy VT3 GPS Watch
27	Cardio Equipment	Bushnell Pro X7 Jolt Slope Rangefinder
28	Cardio Equipment	SOLE E35 Elliptical
29	CDs	CDs of rock
30	Children's Clothing	Children's heaters
31	Cleats	adidas Men's F10 Messi TRX FG Soccer Cleat
32	Cleats	Nike Men's CJ Elite 2 TD Football Cleat
33	Cleats	adidas Kids' F5 Messi FG Soccer Cleat
34	Computers	Dell Laptop
35	Consumer Electronics	Industrial consumer electronics

RECTEGORIZATION

```

mapping_df = pd.read_excel('products_list.xlsx')

unique_cats = mapping_df['new_category'].unique()
cat_to_id = {name: i+1 for i, name in enumerate(unique_cats)}
mapping_df['new_category_id'] = mapping_df['new_category'].map(cat_to_id)

df = df.merge(mapping_df, on='product_name', how='left')

df = df.drop(['category_id', 'category_name'], axis=1)

```

[284] ✓ 0.3s

DATA SPLITTING

```
def create_modular_tables(df):
    customers = df[[
        'customer_id', 'customer_fname', 'customer_lname', 'customer_segment',
        'customer_street', 'customer_zipcode', 'customer_city', 'customer_state', 'customer_country', 'latitude', 'longitude'
    ]].drop_duplicates(subset=['customer_id'])

    products = df[[
        'product_id', 'product_name', 'product_price', 'category_id'
    ]].drop_duplicates(subset=['product_id'])

    categories = df[[
        'category_id', 'category_name', 'department_id', 'department_name'
    ]].drop_duplicates(subset=['category_id'])

    orders = df[[
        'order_id', 'customer_id', 'order_date', 'order_status',
        'type', 'market', 'order_region', 'order_city', 'order_state', 'order_country'
    ]].drop_duplicates(subset=['order_id'])

    items = df[[
        'order_item_id', 'order_id', 'product_id', 'order_item_quantity',
        'order_item_discount', 'order_item_discount_rate', 'sales',
        'order_item_total', 'profit_per_order', 'order_item_profit_ratio'
    ]]

    shipping = df[[
        'order_id', 'shipping_date', 'shipping_days_actual',
        'shipping_days_scheduled', 'shipping_mode', 'delivery_status', 'late_delivery_risk'
    ]].drop_duplicates(subset=['order_id'])

    return customers, products, categories, orders, items, shipping

customers, products, categories, orders, items, shipping = create_modular_tables(df)
```

```
output_dir = 'processed_data'
if not os.path.exists(output_dir):
    os.makedirs(output_dir)

customers.to_csv(f'{output_dir}/customers.csv', index=False)
products.to_csv(f'{output_dir}/products.csv', index=False)
categories.to_csv(f'{output_dir}/categories.csv', index=False)
orders.to_csv(f'{output_dir}/orders.csv', index=False)
items.to_csv(f'{output_dir}/order_items.csv', index=False)
shipping.to_csv(f'{output_dir}/shipping.csv', index=False)

✓ 0.0s
```

02

DATA ANALYSIS

Tools used

Python, SQL, Excel, Power Bi



2.1

**SUPPLY CHAIN
AND SHIPPING
EFFICIENCY**



2.2

SALES



2.3

**MARKETS AND
CUSTOMERS
BEHAVIOR**



2.4

**PRODUCTS
AND
CATEGORIES**

01

SHIPPING PROBLEMS

STRATEGIC ANALYSIS & SOLUTIONS

مشكلة (1): أزمة الوعود بالشحن السريع

الحل المقترح (Action Plan)

→ تعديل خوارزمية المواعيد: إضافة يوم وقائي (Buffer Day) لمطابقة الواقع.

→ نظام الإنذار المبكر Dashboard: لمراقبة Late Risk الحظياً.

→ تعويضات استباقية: إرسال كود خصم آلي فور رصد التأخير لامتناس غضب العميل.

أزمة "First Class"

نسبة التأخير الفعلي تصل إلى 95.27% العميل يدفع مقابل سرعة لا يحصل عليها.

First Class (تأخير)

95.27%

Second Class (تأخير)

76.32%

Standard Class (تأخير)

38.13%

الأثر المالي المباشر للإلغاءات

58%

إلغاء بسبب التأخير

1.57M

القيمة الإجمالية (دولار)

2,855

إجمالي عدد الإلغاءات

الاستنتاج: التأخير هو المحرك الرئيسي لضياع 898 ألف دولار من المبيعات. معالجة التأخير تعني استرداد هذه السيولة فوراً.

التوصيات النهائية (Strategic Roadmap)

تسويقياً

تفعيل نظام "الاعتذار الرقمي" بكوبونات خصم 10% قبل أن يشتكي العميل.

تشغيلياً

إعادة تقييم شركات شحن First Class في الأقاليم المتضررة (Central Asia) أو تغيير المورد.


تقنياً

تعديل خوارزمية الجدولة فوراً للفئات الحرجة (Buffer Day) لضمان صدق الوعود.

أثر تطبيق الحلول (محاكاة النتائج)

استعادة الكفاءة التشغيلية

- **تحويل الحالات:** تحويل 21,130 طلب من "متأخر" إلى "في الموعد".
- **حماية الإيرادات:** تأمين مبيعات بقيمة 10.6 مليون دولار من خطر الإلغاء.
- **الولاء:** زيادة احتمالية عودة العميل بنسبة 40% عند الاعتذار الاستباقي.



الوضع الحالي



الوضع المستقبلي

مشكلة (2): فشل الموردين في فئات محددة

أزمة فئات الجولف والكاميرات

فئات مثل **Golf Shoes** تسجل نسبة تأخير 68.85% المشكلة تكمن في المورد (Lead Time).

Golf Shoes (تأخير المورد)



Cameras (تأخير المورد)



الحل: فرض اتفاقيات مستوى خدمة (SLA) صارمة، وتفعيل "القائمة السوداء" للموردين غير الملتزمين.



عدد الطلبات الفعلي وعدد الطلبات المتأخرة

```
SELECT
COUNT(*) AS Total_Orders,
SUM(CASE WHEN shipping_days_actual > shipping_days_scheduled THEN 1 ELSE 0 END) AS Total_Late_Orders,
(SUM(CASE WHEN shipping_days_actual > shipping_days_scheduled THEN 1 ELSE 0 END) * 100.0 / COUNT(*)) AS Late_Percentage
FROM shipping;
```

Results Messages			
	Total_Orders	Total_Late_Orders	Late_Percentage
1	65749	37697	57.334712315016

تحليل كفاءة التوصيل حسب نوع الشحن ونسبة التأخير

```
SELECT
s.shipping_mode AS [Shipping Mode],
-- إجمالي عدد الطلبات في كل فئة
COUNT(s.order_id) AS [Total Orders],
-- فعلياً "Late delivery" عدد الطلبات التي سُجلت جاليتها
SUM(CASE WHEN s.delivery_status = 'Late delivery' THEN 1 ELSE 0 END) AS [Actual Late Orders],
-- حساب نسبة التأخير الفعلية لتوزيع حجم المشكلة
ROUND(CAST(SUM(CASE WHEN s.delivery_status = 'Late delivery' THEN 1 ELSE 0 END) AS FLOAT) / COUNT(s.order_id) * 100, 2) AS [Late Percentage %]
FROM shipping s
GROUP BY s.shipping_mode
ORDER BY [Late Percentage %] DESC;
```

	Shipping Mode	Total Orders	Actual Late Orders	Late Percentage %
1	First Class	10078	9601	95.27
2	Second Class	12778	9803	76.72
3	Same Day	3571	1648	46.15
4	Standard Class	39322	14995	38.13

تحليل كفاءة الشحن حسب الأقاليم الجغرافية

```
SELECT
o.order_region AS [Region],
COUNT(o.order_id) AS [Total Orders],
-- متوسط أيام التأخير (الفعلي - المخطط)
ROUND(AVG(CAST(s.shipping_days_actual AS FLOAT) - s.shipping_days_scheduled), 2) AS [Avg Delay Days],
-- نسبة خطر التأخير (Late Risk Rate)
ROUND(AVG(CAST(s.late_delivery_risk AS FLOAT)) * 100, 2) AS [Late Risk %],
-- "Late delivery" عدد الحالات التي سُجلت فعلياً
SUM(CASE WHEN s.delivery_status = 'Late delivery' THEN 1 ELSE 0 END) AS [Actual Late Count]
FROM orders o
JOIN shipping s ON o.order_id = s.order_id
GROUP BY o.order_region
HAVING AVG(CAST(s.shipping_days_actual AS FLOAT) - s.shipping_days_scheduled) > 0.5
ORDER BY [Avg Delay Days] DESC;
```

	Region	Total Orders	Avg Delay Days	Late Risk %	Actual Late Count
1	Central Asia	184	0.65	55.43	102
2	Central Africa	556	0.64	57.55	320
3	South of USA	1345	0.6	55.99	753
4	South Asia	3335	0.6	55.92	1865
5	Eastern Europe	1292	0.59	55.96	723
6	East Africa	613	0.59	56.77	348
7	Western Europe	10009	0.59	55.79	5584
8	West Asia	2022	0.58	55.98	1132
9	Southeast Asia	4355	0.58	55.59	2421
10	East of USA	2323	0.58	54.93	1276
11	Eastern Asia	3318	0.57	54.79	1818
12	Oceania	4362	0.57	54.61	2382
13	Central America	9396	0.57	54.87	5156
14	US Center	1935	0.57	55.35	1071
15	West of USA	2667	0.56	54.41	1451
16	South America	4979	0.55	54.15	2696

عدد الأيام المجدولة للشحن وعدد الأيام الفعلي

```
SELECT
    shipping_mode,
    AVG(shipping_days_actual) as Actual,
    AVG(shipping_days_scheduled) as Scheduled
FROM shipping
GROUP BY shipping_mode;
```

	shipping_mode	Actual	Scheduled
1	First Class	2	1
2	Same Day	0	0
3	Standard Class	3	4
4	Second Class	4	2

عرض مشكلة تأخر categories من قبل الموردين

```
SELECT top 15
    c.category_name,
    COUNT(oi.order_id) AS Total_Orders,
    SUM(CASE WHEN s.shipping_days_actual > s.shipping_days_scheduled THEN 1 ELSE 0 END) AS Delayed_Orders,
    ROUND(CAST(SUM(CASE WHEN s.shipping_days_actual > s.shipping_days_scheduled THEN 1 ELSE 0 END) AS FLOAT) / COUNT(oi.order_id) * 100, 2) AS Delay_Rate
FROM order_items oi
JOIN products p ON oi.product_id = p.product_id
JOIN categories c ON p.category_id = c.category_id
JOIN shipping s ON oi.order_id = s.order_id
GROUP BY c.category_name
HAVING COUNT(oi.order_id) > 50
ORDER BY Delay_Rate_Percentage DESC;
```

	category_name	Total_Orders	Delayed_Orders	Delay_Rate_Percentage
1	Golf Shoes	61	42	68.85
2	Cameras	624	388	62.18
3	Pet Supplies	492	302	61.38
4	Men's Clothing	1075	657	61.12
5	Crafts	484	288	59.5
6	Golf Accessories	1893	1126	59.48
7	Music	434	258	59.45
8	Women's Apparel	423	251	59.34
9	Consumer Electronics	430	254	59.07
10	Women's Clothing	1247	732	58.7
11	Health and Beauty	362	212	58.56
12	Golf Bags & Carts	1365	799	58.53
13	Cardio Equipment	730	427	58.49
14	Slides	1455	851	58.49
15	Golf Balls	2029	1186	58.45

02

SALES PERFORMANCE

AND STRATEGIC GROWTH

1. تحليل أوقات الذروة والركود

فجوة الـ 9 أضعاف

المبيعات تنهار في يونيو (\$3,017) وتقفز في أكتوبر (\$27,731). المشكلة في تثبيت ميزانية التسويق طوال العام.

شهر أكتوبر (الذروة)

\$27,731

شهر يونيو (الركود)

\$3,017

الحل والأثر

إعادة الهيكلة: ترحيل ميزانية أضعف 3 شهور لدعم مخزون الذروة.

المال: توفير 30% من المصاريف الإعلانية المهدرة.

الأداء: رفع مبيعات الذروة بنسبة 30% إضافية.

2. مصفوفة الخسائر وتآكل الأرباح

15%

توفير في مساحة المخازن

15-20%

تحسن متوقع في هامش الربح

\$1.3M

نزيف خصومات في فئتين فقط

المشكلة :

القرار: فرض سقف خصم صارم (Discount Cap) وإيقاف التعاقد الفوري مع موردي هذه الفئات.

فئات (Hunting & Shooting) و (Water Sports)
تستنزف السيولة بخصومات هائلة لمجرد محاولة بيع منتجات غير مطلوبة.

3. متوسط الطلب وطرق الدفع

استراتيجية الحوافز الذكية

- تقديم شحن مجاني أو خصم 5% للدفع المسبق بالبطاقة.

- الأثر: زيادة إيرادات شريحة الكاش بنسبة 40% فوراً.

فجوة القيمة الشرائية (\$70)

المتجر يفقد إيرادات محتملة بسبب عملاء الدفع النقدي الذين يشترون سلالاً أرخص.

الدفع الإلكتروني AOV - (TRANSFER/DEBIT)

\$215

الدفع النقدي AOV - (CASH)

\$145

4. الربحية الوهمية والثغرة الأمنية

ثغرة التحويل البنكي (TRANSFER)

اكتشفنا أن 100% من محاولات النصب (Fraud) تتم عبر هذه الطريقة لمنتجات معينة مثل Nike و Perfect Fitness.

DEBIT

الحل: فرض المصادقة الفورية

20%

خفض مستهدف لمعدل الاحتيال

\$20,000+

إيرادات وهمية (Fake Revenue)

5. الارتباط الشرائي واستراتيجية "الطعم"

تحليل سلة المشتريات

الأوردرات التي تتجاوز \$1,400 تحتوي دائماً على منتج مخفض يعمل كـ "طعم" لجذب العميل لشراء منتجات أخرى عالية الربحية.

توصية الـ Bundles

منع بيع "المنتج الخاسر" بمفرده؛ يجب ربطه بمنتجات رابحة ضمن حزم (Bundles) لتعويض الخصم وتحقيق صافي مكسب.

6. الجدوى الحقيقية للخصومات

\$300,000

توفير مباشر عند اعتماد "النسبة الذهبية (10% - 13%) "
كمعيار للحملات.

فخ ال 25%

ندفع أكثر من ضعف التكلفة عند نسبة 25% لنحصل على
نفس المبيعات تقريباً عند نسبة 10%.

تكلفة خصم 25% (\$511k)

21,355 قطعة

تكلفة خصم 10% (\$204k)

21,338 قطعة

7. حساسية السعر جغرافياً

الأثر المالي

تعظيم هوامش الربح الصافي عبر
توجيه الـ ROI للأسواق الأكثر ولاءً
للجودة وليس السعر.

صائدي الخصومات (Hunters)

آسيا الوسطى: خصومات 18%
مقابل إيرادات ضعيفة.
القرار: خفض ميزانية التسويق.

أسواق النخبة (Premium)

شرق آسيا وشمال أوروبا: إيرادات
مليونية بخصومات 4% فقط.
القرار: البيع بالسعر الكامل.

8. مصفوفة التقسيم التجاري للمنتجات

TOP
LEADERS

صناع الأرباح

منتجات (Smart Watches): هوامش استثنائية .
تتطلب برامج ولاء (VIP) وتأمين مخزون استباقي.

MASS
MARKET

محركات السيولة

منتجات (Nike, Perfect Fitness): مبيعات ضخمة
تضمن تدفق الكاش. تستخدم كأدوات جذب
(Bundles).

STRATEGIC ROADMAP

الخلاصة: المال، الأداء، الوقت

+40%

نمو مبيعات الذروة

\$300K

توفير من عقلنة الخصومات

\$1.3M


توفير من الفئات الخاسرة

03

**MARKETS
AND
CUSTOMERS BEHAVIOR**

1.1 التوزيع الجغرافي للمبيعات

Insight 1.1 — Geographic Sales Distribution



Total Sales (\$)

60k
50k
40k
30k
20k
10k

هيمنة الأسواق الرئيسية

هناك 5 أسواق رئيسية تسيطر على إجمالي المبيعات، مع تركيز كبير في بورتوريكو، الولايات المتحدة، وأمريكا اللاتينية. تكرر اسم الولايات المتحدة 4 مرات في قائمة الأعلى مبيعاً مما يعكس تنوعاً جغرافياً داخل الدولة الواحدة.

توصية: التركيز على النمو الآمن

12%

نمو متوقع في المبيعات

3

أهم أسواق مستهدفة

15%

ميزانية تسويق رقمي مقترحة

التركيز الإعلاني على المناطق الأعلى شراءً هو قرار استراتيجي منخفض المخاطر لضمان التوسع المستدام.

1.2 تحليل شرائح العملاء

الأكبر في إجمالي المبيعات

Consumer (Sales)

الأعلى في متوسط قيمة الأوردر

Corporate (AOV)

الشريحة الأكثر تخصصاً

Home Office

التوصية: زيادة معدل تكرار الشراء لشريحة **Corporate** بنسبة 20% عبر برنامج ولاء مخصص،
لتعظيم العائد من الـ AOV المرتفع.

1.3 الموسمية: تحليل الذروة والركود



ديسمبر (الركود): تطبيق خصومات ترويجية (10-15%) لتحفيز المبيعات وتحريك الراكد.


يناير (الذروة): ضرورة زيادة المخزون بنسبة 20% وتكثيف الإعلانات لتقليل نفاذ البضاعة.

معدل الاحتفاظ بالعملاء 1.4

قوة الاحتفاظ بالعملاء

الشركة تمتلك قاعدة قوية حيث أن أكثر من نصف العملاء يعودون للشراء مرة أخرى
بمتوسط 4.8 أورد لكل عميل.

Insight 1.4 — Customer Retention Analysis



→ إطلاق حملة Email Retention تستهدف

العملاء غير النشطين (90) يوم.

→ **الهدف:** رفع معدل الاحتفاظ بنسبة 15%.

1.5 تحليل أنماط الاحتيال

الاحتيال حسب الشريحة

\$825K


إجمالي خسارة الاحتيال المشتبه به
أوروبا وأمريكا اللاتينية هما الأكثر تضرراً

54.3% Consumer


28.1% Corporate

Insight 1.5 — Fraud Pattern Analysis

Fraud Orders by Market



Fraud by Customer Segment



الحل : تفعيل نظام Fraud Scoring تلقائي

لخفض الخسائر بنسبة 40%

ملخص التوصيات الاستراتيجية

→ تحسين الأسواق: تخصيص 15% من الميزانية لأقوى 3 أسواق (USA, PR, LATAM).

→ برامج الولاء: استهداف عملاء Corporate ببرامج مخصصة لرفع المبيعات بنسبة 20%.

→ إدارة المخزون: زيادة المخزون قبل شهر يناير لتفادي الـ Stockouts.


→ الأمان المالي: تطبيق أنظمة تقييم الاحتيال التلقائية في الأسواق عالية الخطورة.

→ تنشيط العملاء: حملات إعادة استهداف بريدية للعملاء المنقطعين منذ 3 أشهر.

04

**PRODUCTS
AND
CATEGORIES**

أزمة "التريند" وسقوط الـ Top 9




مؤشر الخطر (2017 - 2018)

مبيعات أفضل 9 منتجات هبطت للصفر في أكتوبر 2017 بعد هبوط مستمر منذ أغسطس. استمر عدم الاستقرار لمدة 5 أشهر، وهو ما يمثل تهديد وجودي للشركة إذا استمر الوضع لفترات أطول.

التوصية: نموذج "الهايبرد"

بدلاً من انتظار هبوط الكيرف، نقوم ببناء "كيرف" جديد موازي عبر تجربة المنتجات باستمرار.



5%

تخصيص ميزانية
للتجارب الجديدة

السيناريو التحفظي (تجنب الانهيار)

حماية قاع الأرباح

يهدف هذا السيناريو إلى الحفاظ على استقرار
المتجر ومنع الانهيار المالي عند سقوط المنتجات
القديمة من التريند.
النتيجة: ضمان استمرار الأرباح عند مستوى آمن
يمنع الخسائر التشغيلية.

الربح الشهري (نموذج الهايبرد)

\$111,000


الربح الشهري (الوضع الحالي)

\$80,000

28%

رفع متوقع للربحية
وقت الركود

السيناريو المتفائل (اقتناص القمم)



اكتشاف "المنتجات الخارقة" مثل منتج Dell Laptop

اكتشاف المنتج قبل وصوله للذروة بـ 5 أشهر يغير المعادلة المالية بالكامل.

10.98%

هامش الربح المستهدف للمنتج


\$274.5K

إجمالي أرباح مضافة في 5 شهور

\$54.9K

صافي ربح شهري للمنتج الواحد

القوة المالية: سد فجوة الركود



معالجة العجز المالي

الأرباح الناتجة من منتج "خارق" واحد كفيلة بتغطية فجوة أرباح الركود بالكامل (\$156,451).

\$118,049 فائض ربح فوق المعتاد بعد

سد الفجوة.

المقارنة بين فترة الاستقرار والركود ونظام الهايبرد

```
df['order_date'] = pd.to_datetime(df['order_date'])

stability_start = '2015-01-01'
stability_end = '2017-09-01'
recession_end = '2018-01-30'

stability_df = df[(df['order_date'] >= stability_start) & (df['order_date'] < stability_end)]
recession_df = df[(df['order_date'] >= stability_end) & (df['order_date'] < recession_end)]

monthly_sales_stb = stability_df['sales'].sum() / 32
monthly_sales_rec = recession_df['sales'].sum() / 5
monthly_cost_stb = stability_df['product_price'].sum() / 32
monthly_cost_rec = recession_df['product_price'].sum() / 5
monthly_profit_stb = stability_df['profit_per_order'].sum() / 32
monthly_profit_rec = recession_df['profit_per_order'].sum() / 5

sales_drop_pct = ((monthly_sales_stb - monthly_sales_rec) / monthly_sales_stb) * 100
cost_drop_pct = ((monthly_cost_stb - monthly_cost_rec) / monthly_cost_stb) * 100
profit_drop_pct = ((monthly_profit_stb - monthly_profit_rec) / monthly_profit_stb) * 100

margin_stb = monthly_profit_stb / monthly_sales_stb
margin_rec = monthly_profit_rec / monthly_sales_rec
target_sales = monthly_sales_stb

profit_from_stb_part = (target_sales * 0.95) * margin_stb
profit_from_rec_part = (target_sales * 0.05) * margin_rec
hybrid_monthly_profit = profit_from_stb_part + profit_from_rec_part
```

--- فترة الاستقرار (شهرياً) ---
المبيعات: 1,034,515.33\$
التكلفة الحقيقية: 692,042.60\$

--- فترة الركود (شهرياً) ---
المبيعات: 730,189.13\$
التكلفة الحقيقية: 664,099.33\$

--- معدلات الهبوط ---
%نسبة الهبوط في الأداء المالي: 29.42
%نسبة الهبوط في التكلفة: 4.04
%نسبة الهبوط في الربح: 28.00

%نسبة ربح الاستقرار الفعلية: 10.76
%نسبة ربح الركود الفعلية: 10.98

الربح الشهري الصافي فترة الاستقرار: 111,360.08\$
الربح الشهري الصافي فترة الركود: 80,181.76\$
الربح الشهري المتوقع (نموذج 95/5): 111,472.06\$

CONCLUSION

الخلاصة والتوصيات الاستراتيجية

الأداء المالي والربحية

إيقاف نزيف الفئات الخاسرة (\$1.3M) وعقلنة الخصومات عند
"النقطة الذهبية" (10-13%) "يوفر للشركة 1.6 مليون دولار
سنوياً تضاف لصافي الربح.

استراتيجية النمو (Hybrid)

تخصيص 5% لمشاريع الابتكار يضمن استدامة منحنى النمو
(S-Curve) وسد فجوة أرباح الركود عبر اكتشاف "المنتجات
الخارقة" قبل المنافسين.

سلاسل الإمداد والشحن

معالجة فشل الشحن السريع (First Class) عبر "اليوم الوقائي"
تحمي 10.6 مليون دولار من الإيرادات المعرضة للخطر وتخفض
مخاطر التأخير بنسبة 50%

سلوك الأسواق والعملاء

تحويل 30% من عملاء الكاش إلى الدفع الإلكتروني يرفع قيمة
الطلب (AOV) بنسبة 40%، مع ضرورة غلق ثغرة التحويل البنكي
(Transfer) لوقف الاحتيال.

THANKS!

Inspirational words

